

Министерство науки и высшего образования РФ
Федеральное государственное автономное образовательное учреждение
высшего образования
«Национальный исследовательский технологический университет
«МИСИС»

Институт компьютерных наук (ИKN)
Кафедра инфокоммуникационных технологий (ИКТ)

КУРСОВАЯ РАБОТА

по дисциплине «Методы анализа и обработки естественного языка»
на тему «NER в финансовой области»

Выполнил:
студент группы МПИ-25-1-2

Фам Минь Хиеу

Подпись: _____

Проверил:
ст. преп. Ерилова И.И.

Дата сдачи: «____» _____ 202__ г.

Оценка: _____ Подпись: _____

Москва, 2026

Содержание

1. Введение.....	3
2. Теоретические основы NER в финансовой сфере.....	5
2.1. Понятие и применение NER.....	5
2.2. Обзор подходов: CRF, DistilBERT, FinBERT.....	6
2.2.1. CRF (Conditional Random Fields).....	6
2.2.2. DistilBERT.....	6
2.2.3. FinBERT.....	7
2.3. Сводная схема pipeline для всех трёх подходов.....	8
2.4. Сравнительная таблица подходов.....	9
3. Данные и предобработка.....	10
3.1. Описание набора данных tner/fin.....	10
3.2. Исследовательский анализ данных (EDA).....	11
3.3. Токенизация и выравнивание меток.....	13
4. Модели и подходы.....	14
4.1. Дообучение FinBERT.....	14
4.2. Дообучение DistilBERT.....	15
4.3. Классическая модель CRF.....	15
5. Эксперименты и анализ результатов.....	16
5.1. Протокол эксперимента и гиперпараметры.....	16
5.2. Сравнение результатов.....	17
5.3. Анализ ошибок.....	18
Заключение.....	21
Список использованных источников.....	22

1. Введение

Современный этап технологического развития в финансовой сфере характеризуется экспоненциальным ростом объёмов текстовых данных: договоры, отчёты, новости, аналитические обзоры, нормативно-правовые акты. В условиях ужесточения регуляторных требований и необходимости оперативного анализа больших массивов неструктурированной информации задачи извлечения знаний из текста приобретают первостепенное значение. Особую актуальность в этой области имеет технология извлечения именованных сущностей (Named Entity Recognition, NER), позволяющая автоматически идентифицировать в тексте ключевые объекты: организации, личности, географические названия и другие сущности [1]. Применение NER в финансовой отрасли становится стратегическим элементом для автоматизации обработки документов, оценки рисков, выявления инсайдерской информации и соответствия требованиям комплаенс.

Целью работы является проведение сравнительного анализа различных подходов к решению задачи извлечения именованных сущностей в финансовых текстах на основе открытого датасета tner/fin [2].

Достижение этой цели планируется через последовательное решение следующих **задач**:

- Описание используемого набора данных: источник, структура, особенности, распределение классов.
- Проведение исследовательского анализа данных (EDA) для выявления дисбаланса классов и статистических характеристик.
- Реализация трёх различных методов NER: дообучение доменно-специфичной модели FinBERT, дообучение базовой модели DistilBERT, классическая модель CRF с ручным конструированием признаков.

- Проведение экспериментов с несколькими вариантами гиперпараметров для каждого подхода (минимум 3).
- Сравнение моделей на основе метрик точности (Precision), полноты (Recall) и F1-меры.
- Анализ типичных ошибок и сложных случаев для каждого метода.
- Формулирование выводов о преимуществах и ограничениях рассмотренных подходов.

Объект исследования: финансовые тексты на английском языке, включающие юридическую и экономическую терминологию (договоры, соглашения, отчёты).

Предмет исследования: методы и модели машинного обучения для извлечения именованных сущностей (CRF, DistilBERT, FinBERT), их архитектуры, процессы дообучения и оценки качества.

Методы исследования:

- Качественный анализ структуры данных и распределения меток (EDA).
- Токенизация и выравнивание меток для трансформерных моделей.
- Дообучение предобученных языковых моделей (FinBERT, DistilBERT) с использованием библиотек Hugging Face и PyTorch.
- Классический подход на основе условных случайных полей (CRF) с ручным конструированием лингвистических признаков.
- Сравнительный анализ результатов с использованием метрик Precision, Recall, F1 (библиотека seqeval [2]).

Практическая значимость работы заключается в возможности использования полученных результатов для внедрения NER-систем в автоматизированные системы обработки финансовых документов, а также для выбора наиболее эффективной модели в зависимости от требований к

скорости и точности.

Структура работы включает введение, три основные главы, раздел с экспериментами и анализом результатов, заключение и список использованных источников. Логика исследования построена следующим образом: первая глава посвящена теоретическим основам NER и обзору подходов, вторая — характеристике и предобработке данных, третья — описанию реализованных моделей. В отдельном разделе представлены эксперименты, сравнение результатов и анализ ошибок.

Датасет `tner/fin` представляет собой репрезентативный объект для демонстрации применения NER в финансовой области благодаря наличию размеченных сущностей (PER, ORG, LOC, MISC), реалистичной структуре документов и возможности объективного сравнения методов [3].

2. Теоретические основы NER в финансовой сфере

2.1. Понятие и применение NER

Named Entity Recognition (NER) — распознавание именованных сущностей — является одной из ключевых подзадач в области обработки естественного языка (Natural Language Processing, NLP). Основная цель NER заключается в автоматическом выделении в тексте слов и словосочетаний, обозначающих именованные объекты, и их классификации по заранее определённым категориям. К числу наиболее распространённых категорий относятся имена людей (Person, PER), названия организаций (Organization, ORG), географические названия (Location, LOC), даты, события и термины предметных областей.

В финансах NER используется для автоматической обработки договоров, отчётов, новостей, что позволяет ускорить compliance-контроль, оценку рисков и анализ контрагентов.

2.2. Обзор подходов: CRF, DistilBERT, FinBERT

2.2.1. CRF (Conditional Random Fields)

CRF [3] эффективен при ограниченном объёме размеченных данных (в датасете ~1000 предложений). Он моделирует зависимости между соседними метками, что критически важно для правильного выделения границ сущностей (например, последовательность B-PER → I-PER). Финансовые тексты содержат чёткие структурные паттерны (заглавные буквы, суффиксы), которые можно задать вручную.

Архитектура / Pipeline:

- Извлечение признаков для каждого токена:
 - Лингвистические: нижний регистр, суффиксы (-ing, -tion), наличие заглавной буквы, цифр.
 - Контекстуальные: признаки соседних слов (окно = 2).
- Моделирование переходов между метками (O, B-PER, I-PER, ...) с помощью условных случайных полей.
- Обучение (алгоритм L-BFGS) на последовательностях признаков с оптимизацией условной вероятности.
- Предсказание – поиск наиболее вероятной последовательности меток алгоритмом Витерби.

2.2.2. DistilBERT

DistilBERT [4] – это дистиллированная (сжатая) версия BERT, сохраняющая 95% качества при уменьшении размера модели на 40% и ускорении в 60%. Она обеспечивает глубокое контекстуальное понимание за счёт двунаправленного механизма внимания, что важно для финансовых текстов, где значение слова зависит от окружения («банк» может быть организацией или инструментом). DistilBERT не требует ручного

конструирования признаков и служит эффективным базовым уровнем (baseline) для сравнения с доменными моделями.

Архитектура / Pipeline:

- Токенизация (WordPiece) с добавлением специальных токенов [CLS], [SEP].
- Выравнивание меток: субсловные токены получают метку -100 (игнорируются при подсчёте ошибки).
- Добавление классификационной головы (линейный слой) над выходами каждого токена последнего слоя.
- Дообучение (fine-tuning) с кросс-энтропийной потерей на тренировочных данных.
- Оптимизатор AdamW, три варианта гиперпараметров (learning rate $2e-5$, $5e-5$, $3e-5$; размер батча 16, 16, 8; число эпох 3,5,4).
- Предсказание: argmax по выходным логитам, удаление субсловных меток.

2.2.3. FinBERT

FinBERT (ProsusAI/finbert) [5] – это расширение BERT [6] с дополнительным предобучением на корпусе финансовых документов (отчёты SEC, новости, аналитические статьи) [7]. Архитектурно он идентичен BERT (12 слоёв, 768 скрытых размеров), но благодаря доменной адаптации лучше распознаёт финансовую терминологию, аббревиатуры и специфические синтаксические конструкции. Это даёт более высокую точность на финансовых текстах по сравнению с универсальными моделями.

Архитектура / Pipeline:

- Полностью повторяет pipeline DistilBERT, но с инициализацией

весов из модели, дообученной на финансовых данных.

- Токенизация, выравнивание меток, линейная голова.
- Дообучение на том же NER-датасете с теми же вариантами гиперпараметров (3 варианта).
- Благодаря предобучению на финансовых текстах требует меньше эпох для сходимости.

2.3. Сводная схема pipeline для всех трёх подходов

Загрузка и подготовка данных:

- Загрузка датасета tner/fin из трёх JSON-файлов (train, validation, test).
- Преобразование целочисленных меток в строки IOB2 (8 классов).
- Анализ распределения меток и длины предложений.

Pipeline для трансформерных моделей (FinBERT, DistilBERT):

- Токенизация с помощью AutoTokenizer, выравнивание меток (word_ids, метка только первому субтокену, остальным -100).
- Загрузка моделей ProsusAI/finbert и distilbert-base-uncased с классификационной головой на 8 классов.
- Перебор трёх наборов гиперпараметров (H1, H2, H3): разный learning rate, batch size, число эпох.
- Обучение через Trainer с DataCollatorForTokenClassification, валидация по F1, сохранение лучшей модели.
- Оценка на тестовой выборке, вычисление precision, recall, F1 через seqeval.

Pipeline для CRF (sklearn-crfsuite [8]):

- Ручное извлечение признаков: нормализация слова, окончания, регистр, флаги BOS/EOS, контекст ± 1 слово.

- Преобразование предложений в последовательности признаков и меток.
- Обучение CRF с алгоритмом lbfgs, три варианта гиперпараметров (c1, c2).
- Предсказание на тесте, оценка через seqeval.

Сравнение результатов:

- Сбор лучших показателей каждой модели.
- Построение сравнительной таблицы и графиков F1-мер.

2.4. Сравнительная таблица подходов

Таблица 1 - Сравнительная характеристика подходов CRF, DistilBERT и FinBERT

Подход	Тип	Преимущества	Недостатки
CRF	Классический вероятностный	Работает на малых данных, интерпретируем, учитывает соседние метки	Ручное конструирование признаков, не использует глубокие семантические представления
DistilBERT	Трансформер (облегчённый)	Высокая скорость, малый размер, хорошее контекстуальное понимание, baseline	Уступает в точности доменным моделям на специализированных текстах
FinBERT	Трансформер (доменный)	Лучшее понимание финансовой терминологии, высокая точность	Большой размер, требует больше ресурсов, чем DistilBERT

3. Данные и предобработка

3.1. Описание набора данных tner/fin

В работе используется открытый набор данных tner/fin [1], предназначенный для задачи извлечения именованных сущностей в финансовой области. Данные загружены с платформы Hugging Face по прямым ссылкам:

- train.json – обучающая выборка
- valid.json – валидационная выборка
- test.json – тестовая выборка

Каждый образец представляет собой предложение (или документ), разбитое на токены, с приписанными к каждому токену метками в формате IOB2 (Inside-Outside-Begin). Набор данных содержит следующие типы сущностей:

- PER – имена людей
- ORG – организации
- LOC – географические локации
- MISC – прочие сущности (например, названия законов, валют, финансовые инструменты)

Размер выборок:

- Обучающая выборка: 1018 предложений,
- Валидационная выборка: 150 предложений,
- Тестовая выборка: 305 предложений.

Каждый образец содержит два поля:

- tokens – список слов/токенов
- tags – список меток IOB в виде целочисленных идентификаторов (в процессе предобработки преобразованы в строковые метки)

3.2. Исследовательский анализ данных (EDA)

На обучающей выборке было подсчитано распределение меток (в формате IOB). Результаты показали сильный дисбаланс классов: подавляющее большинство токенов (более 96%) не являются именованными сущностями (метка O). Среди именованных сущностей наиболее частотными являются B-PER (1.78%) и I-ORG (0.49%). Редкие метки, такие как I-LOC, встречаются всего 7 раз (0.02%). Это типичная ситуация для NER-датасетов и требует использования метрик, устойчивых к дисбалансу (Precision, Recall, F1).

```
=== Statistical dataset ===  
train: 1018 samples  
validation: 150 samples  
test: 305 samples
```

```
=== Label distribution on the train ===  
O: 35255 (96.35%)  
B-PER: 650 (1.78%)  
I-ORG: 178 (0.49%)  
B-LOC: 172 (0.47%)  
I-PER: 158 (0.43%)  
B-MISC: 134 (0.37%)  
B-ORG: 36 (0.10%)  
I-LOC: 7 (0.02%)
```




Рисунок 1 – Распределение меток IOB (логарифмическая шкала)

Анализ длины предложений (в количестве токенов) показал, что большинство предложений имеют умеренную длину, однако встречаются и длинные тексты (вплоть до 641 токена в тестовой выборке). Статистика:

```
=== Statistics on sentence length (number of tokens) ===  
Train: mean=35.9, std=41.9, min=1, max=413  
Validation: mean=29.5, std=32.2, min=3, max=212  
Test: mean=43.4, std=63.7, min=1, max=641
```




Рисунок 2 – Распределение длины предложений (количество токенов)

Гистограммы распределения длины показывают, что основная масса предложений имеет длину до 100 токенов. Наличие длинных предложений (более 512 токенов) потребовало использования усечения (truncation) при токенизации трансформерами.

```
=== Ví dụ mẫu từ tập train (5 mẫu đầu tiên) ===
```

```
--- Mẫu 1 ---
```

```
Tokens: ['(', 'l', ')', ' ', 'Tranche', 'A', 'Shares', ' ', 'has', 'the', 'meaning', 'as', 'defined', 'in', 'the', 'Subscription', 'Agreement', '.']  
NER tags: ['O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O']  
Chi tiết: [(('(', 'O'), ('l', 'O'), (')', 'O'), (' ', 'O'), ('Tranche', 'O'), ('A', 'O'), ('Shares', 'O'), (' ', 'O'), ('has', 'O'), ('the', 'O')) ...
```

```
--- Mẫu 2 ---
```

```
Tokens: ['(', 'm', ')', ' ', 'Tranche', 'B', 'Cash', 'Payment', ' ', 'has', 'the', 'meaning', 'as', 'defined', 'in', 'the', 'Subscription', 'Agreement', '.']  
NER tags: ['O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O']  
Chi tiết: [(('(', 'O'), ('m', 'O'), (')', 'O'), (' ', 'O'), ('Tranche', 'O'), ('B', 'O'), ('Cash', 'O'), ('Payment', 'O'), (' ', 'O'), ('has', 'O')) ...
```

```
--- Mẫu 3 ---
```

```
Tokens: ['(', 'n', ')', ' ', 'USD', ' ', 'means', 'US', 'dollars', ' ', 'the', 'lawful', 'currency', 'of', 'the', 'United', 'State', 'of', 'America', '.']  
NER tags: ['O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O', 'O']  
Chi tiết: [(('(', 'O'), ('n', 'O'), (')', 'O'), (' ', 'O'), ('USD', 'O'), (' ', 'O'), ('means', 'O'), ('US', 'O'), ('dollars', 'O'), (' ', 'O')) ...
```

Рисунок 3 – Примеры образцов из обучающего набора данных.

3.3. Токенизация и выравнивание меток

Датасет уже предоставлен в предобработанном виде: токены уже выделены, нет лишних символов или артефактов. Дополнительная очистка не требовалась.

Для моделей DistilBERT и FinBERT использована субсловная токенизация (WordPiece) с помощью AutoTokenizer [9]. Поскольку модели работают с субсловами, а исходные метки даны для целых слов, необходимо выравнивание меток.

Алгоритм выравнивания:

- Каждое предложение токенизируется с параметром `is_split_into_words=True`
- Для каждого токена получаем `word_id` – индекс исходного слова, к которому он относится.
- Первому субслову каждого исходного слова присваивается соответствующая NER-метка (например, B-PER).
- Остальным субсловам (начиная со второго) присваивается метка -100, которая игнорируется при вычислении функции потерь (cross-entropy) в процессе обучения.
- Специальные токены [CLS], [SEP], а также токены паддинга также получают метку -100.

Для классической модели CRF предобработка включала извлечение вручную заданных лингвистических признаков для каждого токена:

- Признаки самого слова: нижний регистр, последние 2 и 3 символа, является ли слово заглавным, имеет ли заглавную первую букву, является ли числом.
- Контекстные признаки: аналогичные признаки для предыдущего и следующего слова (если они существуют).

- Флаги начала и конца предложения (BOS, EOS).

Итоговая структура данных после предобработки:

- Для трансформеров: `input_ids`, `attention_mask`, `labels` (список целых чисел, где -100 – игнорируемые позиции)
- Для CRF: список признаковых векторов для каждого предложения и соответствующий список меток.

Такая предобработка обеспечила корректное обучение и оценку всех трёх моделей на едином датасете.

4. Модели и подходы

4.1. Дообучение FinBERT

Базовая архитектура: трансформерная модель BERT с 12 слоями, 768 скрытыми размерами и 12 головками внимания (около 110 млн параметров). Добавлен классификационный слой (линейный) для токен-классификации с 8 выходными нейронами (соответствует 8 меткам IOB: O, B-LOC, I-LOC, B-MISC, I-MISC, B-ORG, I-ORG, B-PER, I-PER).

Pipeline: загрузка модели из Hugging Face; субсловная токенизация WordPiece; выравнивание меток (субсловам, кроме первого, присваивается -100); дообучение с кросс-энтропийной потерей; оптимизатор AdamW (weight decay 0.01).

Три варианта гиперпараметров:

Вариант	Learning rate	Batch size	Epochs
H1	2e-5	16	3
H2	5e-5	16	5
H3	3e-5	8	4

4.2. Дообучение DistilBERT

Архитектура: 6 слоёв трансформера, 768 скрытых размеров, 12 голов внимания (около 66 млн параметров).

Классификационная голова – линейный слой на 8 выходов.

Pipeline полностью повторяет pipeline FinBERT, но с инициализацией весов из distilbert-base-uncased. Используются те же три варианта гиперпараметров

Вариант	Learning rate	Batch size	Epochs
H1	2e-5	16	3
H2	5e-5	16	5
H3	3e-5	8	4

4.3. Классическая модель CRF

CRF эффективен при ограниченном объёме размеченных данных (в датасете ~1000 предложений). Он моделирует зависимости между соседними метками, что критически важно для правильного выделения границ сущностей. В финансовых текстах присутствуют чёткие структурные паттерны (заглавные буквы, суффиксы, цифры), которые можно задать вручную.

Для каждого токена извлекаются лингвистические признаки (нижний регистр, последние 2–3 символа, наличие заглавной буквы, первая заглавная буква, является ли число) и контекстные признаки (аналогичные признаки для предыдущего и следующего слова, а также флаги начала и конца предложения).

Используется библиотека sklearn-crfsuite с алгоритмом L-BFGS.

Три варианта параметров регуляризации:

Вариант	c1	c2	max_iterations
H1	0.1	0.1	100
H2	0.01	0.01	100
H3	1	1	100

Все модели обучались на одном и том же разбиении данных (1018 предложений – обучение, 150 – валидация, 305 – тест). Для нейросетевых моделей использовалась ранняя остановка по лучшему F1 на валидационной выборке.

5. Эксперименты и анализ результатов

5.1. Протокол эксперимента и гиперпараметры

Эксперименты проводились на открытом датасете `tner/fin` с фиксированным разбиением на обучающую (1018 предложений), валидационную (150 предложений) и тестовую (305 предложений) выборки. Качество моделей оценивалось по метрикам точности (Precision), полноты (Recall) и F1-меры (макроусреднение) с использованием библиотеки `seqeval`.

Гиперпараметры для каждого подхода приведены выше. Всего для каждой модели было обучено по три варианта (H1, H2, H3), что соответствует требованию минимум трёх комбинаций гиперпараметров.

На рисунке ниже изображена зависимость F1-меры от выбора гиперпараметров для всех трёх моделей. Видно, что нейросетевые модели чувствительны к `learning rate` и числу эпох, в то время как CRF демонстрирует более стабильные результаты в диапазоне параметров регуляризации.



Рисунок 4 – Зависимость F1-меры от выбора гиперпараметров (H1, H2, H3) для каждой модели

5.2. Сравнение результатов

Подробные результаты по каждому варианту гиперпараметров:

=== Details of all variations ===

Model	Variant	Precision	Recall	F1
CRF	H1	0.876325	0.596154	0.709585
CRF	H2	0.873239	0.596154	0.708571
CRF	H3	0.941423	0.540865	0.687023
DistilBERT	H1	0.822878	0.541262	0.653001
DistilBERT	H2	0.807388	0.742718	0.773704
DistilBERT	H3	0.747748	0.805825	0.775701
FinBERT	H1	0.782609	0.655340	0.713342
FinBERT	H2	0.776978	0.786408	0.781665
FinBERT	H3	0.766292	0.827670	0.795799

Рисунок 5 – Сравнение метрик Precision, Recall и F1-score для трёх подходов (FinBERT, DistilBERT, CRF) на тестовой выборке

Лучший F1-счёт достигнут моделью FinBERT в варианте H3 (0.7958). Высокая полнота (Recall = 0.8277) подтверждает, что доменная предварительная адаптация критически важна для финансовых текстов.

DistilBERT показал результат 0.7757, что лишь на 2% хуже, но при значительно меньшем размере модели и времени инференса. CRF, несмотря на самую высокую точность в варианте НЗ (0.9414), серьёзно уступает по полноте (0.5409), что делает его непригодным для задач, где важна максимальная полнота обнаружения сущностей.

На следующем рисунке представлено сравнение Precision, Recall и F1-score для лучшего варианта каждой модели.

=== Compare the three models (best value according to F1) ===

Model	Precision	Recall	F1-score
FinBERT	0.766292	0.827670	0.795799
DistilBERT	0.747748	0.805825	0.775701
CRF	0.876325	0.596154	0.709585




Рисунок 6 – Сравнение метрик Precision, Recall и F1-score для трёх подходов (FinBERT, DistilBERT, CRF) на тестовой выборке

5.3. Анализ ошибок

Анализ ошибочных предсказаний на тестовой выборке (305 примеров) позволил выявить типичные проблемы для каждого подхода.

Для нейросетевых моделей (FinBERT и DistilBERT): Наиболее частые ошибки связаны со смещением типов сущностей и неверным

определением границ:

- Смещение B-ORG (организация) и B-PER (человек). Например, в предложении «subordinated loan agreement HERBERT SMITH LLP» модель DistilBERT предсказала B-PER для SMITH, тогда как истинная метка – B-ORG.
- Ошибки в составных сущностях: B-MISC предсказывается как I-PER (FinBERT), либо B-LOC и B-MISC пропускаются (DistilBERT).
- Проблемы границ: модель правильно определяет тип, но неверно отмечает начало или конец (например, B-ORG вместо I-ORG, или наоборот).
- Пропуск редких типов: сущности типа LOC, MISC, ORG распознаются хуже из-за их малой представленности в обучающей выборке (менее 1% для каждого).

Основная причина – сильный дисбаланс классов (метка O составляет 96,35% обучающих токенов) и неоднозначность контекста (одно и то же слово может быть именем, организацией или географическим названием).

Для модели CRF:

- Главная проблема – низкая полнота (recall) при высокой точности. Для лучшего варианта H3 ($c_1=1,0$, $c_2=1,0$) точность составила 0,941, но полнота – лишь 0,541.
- Модель часто даёт метку O там, где должна быть именованная сущность, особенно если сущность не имеет явных признаков (заглавные буквы, цифры, типовые шаблоны).
- Лучше всего распознаёт персон (PER): $F1 = 0,8835$. Гораздо хуже – географические названия (LOC, $F1=0,3765$) и прочие сущности (MISC, $F1=0,0308$).
- Пример: в предложении «The language ... shall be English» модель CRF не распознала English как локацию (I-LOC).

Общие выводы по ошибкам:

- Ключевая проблема всех трёх подходов – дисбаланс классов в обучающей выборке. Это приводит к тому, что модели реже предсказывают редкие классы (ORG, MISC, LOC).
- Нейросетевые модели значительно превосходят CRF по полноте и общей F1-мере (0,796 у FinBERT против 0,710 у CRF), но допускают больше ошибок классификации типов сущностей.
- Для улучшения качества можно предложить: аугментацию данных для редких типов, постобработку правилами (например, словари организаций и локаций), ансамблирование нейросетевой модели и CRF для повышения точности при сохранении полноты.

.

Заключение

В ходе выполнения работы были реализованы и сравнены три подхода к извлечению именованных сущностей (NER) в финансовых текстах на английском языке: классическая модель условных случайных полей (CRF) и две трансформерные модели – облегчённая DistilBERT и доменно-специфичная FinBERT. Обучение и оценка проводились на открытом датасете tner/fin, содержащем 1018 размеченных предложений из договоров и соглашений.

Наилучший результат по F1-мере (0,7958) показала модель FinBERT с гиперпараметрами H3 (learning rate = $3e-5$, batch size = 8, 4 эпохи). Высокий показатель полноты (Recall = 0,8277) подтверждает эффективность доменной предварительной адаптации в финансовой сфере. DistilBERT достиг $F1 = 0,7757$ при значительно меньших вычислительных затратах, что делает его привлекательным для практических систем с ограниченными ресурсами. CRF продемонстрировал самую высокую точность (Precision = 0,8763), но низкую полноту (Recall = 0,5962), что ограничивает его применение в задачах, требующих максимального обнаружения сущностей.

Основным ограничением всех трёх подходов является сильный дисбаланс классов в исходных данных, что приводит к редким предсказаниям для этих категорий. Типичные ошибки связаны со смешением типов сущностей, особенно ORG и PER, и с неверным выделением границ.

Перспективы дальнейших исследований включают: аугментацию данных для редких типов, применение техник пост-обработки (словари организаций), использование ансамблей нейросетевых моделей и CRF, а также эксперименты с более современными языковыми моделями (например, FinBERT-2 или Llama-3 для few-shot NER). Все исходные коды и результаты приведены в ноутбуке [9].

Список использованных источников

1. Hugging Face. "tner/fin dataset". [Электронный ресурс]. URL: <https://huggingface.co/datasets/tner/fin> (дата обращения: 26.4.2026).
2. Библиотека для оценки качества NER [Электронный ресурс]. URL: <https://github.com/chakki-works/seqeval> (дата обращения: 26.4.2026).
3. Lafferty J., McCallum A., Pereira F. Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data. In: Proceedings of ICML, 2001, pp. 282–289.
4. Sanh V., Debut L., Chaumond J., Wolf T. DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter. arXiv preprint arXiv:1910.01108, 2019.
5. ProsusAI. FinBERT: Financial Sentiment Analysis with BERT. Model card on Hugging Face. URL: <https://huggingface.co/ProsusAI/finbert> (дата обращения: 20.04.2026).
6. Devlin J., Chang M.W., Lee K., Toutanova K. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: Proceedings of NAACL-HLT, 2019, pp. 4171–4186.
7. FinBERT-2 [Электронный ресурс]. URL: <https://huggingface.co/ProsusAI/finbert2> (дата обращения: 26.4.2026).
8. Библиотека sklearn-crfsuite [Электронный ресурс]. URL: <https://github.com/chakki-works/seqeval> (дата обращения: 26.4.2026).
9. Документация Hugging Face по NER [Электронный ресурс]. URL: https://huggingface.co/docs/transformers/tasks/token_classification (дата обращения: 26.4.2026).
10. МПИ_25_1_2_Фам_Минь_Хиеу_Курсовая_работа [Электронный ресурс]. URL: https://colab.research.google.com/drive/1Rso53Utdw3rG4_2IdFoWojFcYG2aDylR?usp=sharing (дата обращения: 26.4.2026).